Aula 2: MCP I

Prof. Ioannis Eleftheriou

IOANNIS PEDRO ELEFTHERIOU

/ioannispedroeleftheriou

“Nenhuma boa ação sairá impune”

- Level: 30
- Classe: Especialista de IA e professor de Engenharia de Machine Learning e AI Scientist na FIAP
- Subclasse: MBA em Data Science pela FIAP e Bacharel em Game Design
- Analista Arcano: Mais de 10 anos de experiência com Crédito e Dados
- Empresas que atuei: HSBC, Bradesco, Vortx, Itaú, Grupo Boticário
- Criador de universos visuais e narrativas que tornam o conhecimento acessível e inspirador — da lousa ao código.

Agenda da Semana

MCP I

Mentoria 1 - Definição do Projeto (Obrigatória)

Opt. 2 - 20/05
Opt 3 - 27/05

MCP II - Hands On Prático

O que veremos hoje

- Cases e Indicações
- MCP I
- Como aplicar no BV Assist
- Hands On Guiado

/ Cases

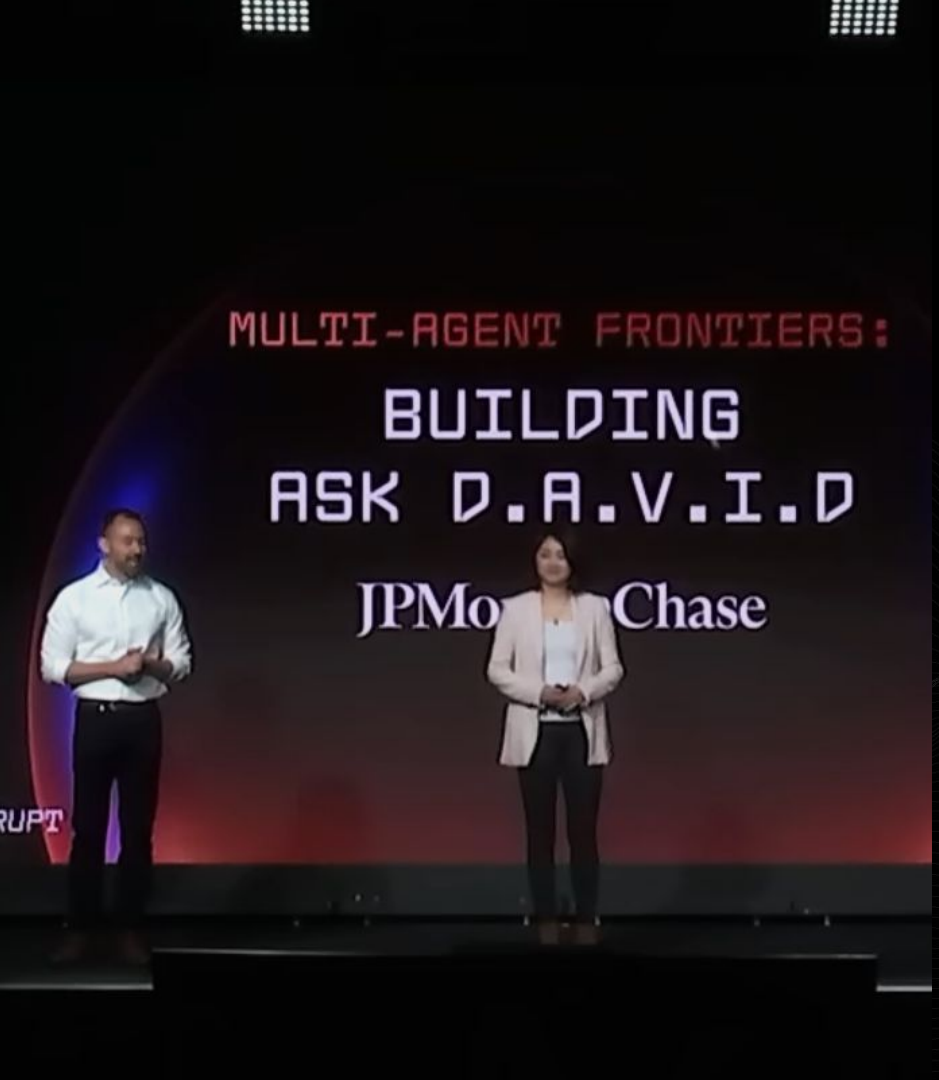

/ JPMorgan Chase

- Da pesquisa manual à precisão impulsionada por IA.
- Ask David é um sistema multiagente, orquestrado por um supervisor.
- Converte consultas NL em chamadas SQL ou de API.
- Gera resumos concisos por meio do LLM

Fonte da imagem: https://www.youtube.com/watch?v=yMalr0jiOAc

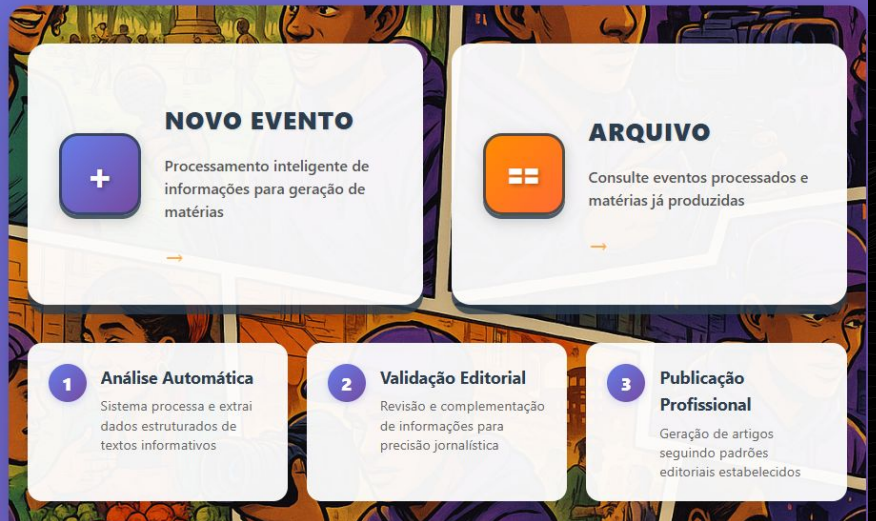

/ Contaí Reporter

- MVP de sistema multi agentes para registro e documentação de eventos
- Utilizando FastAPI + LangGraph e CrewAI com sistema multiagente, orquestrado por um supervisor.
- Converte texto livre em artigos jornalísticos e popula registro de eventos no banco de matérias

Fonte da imagem: https://contai-reporter.onrender.com/

/ Qual a diferença entre MCP e RAG?

/ Chat genérico vs Extração estruturada

Modelos de linguagem são gerativos, não determinísticos, então a mesma pergunta raramente vem exatamente igual duas vezes.

Em extração estruturada, ao invés de uma resposta em texto livre, buscamos que a IA produza dados em um formato padronizado e previsível.

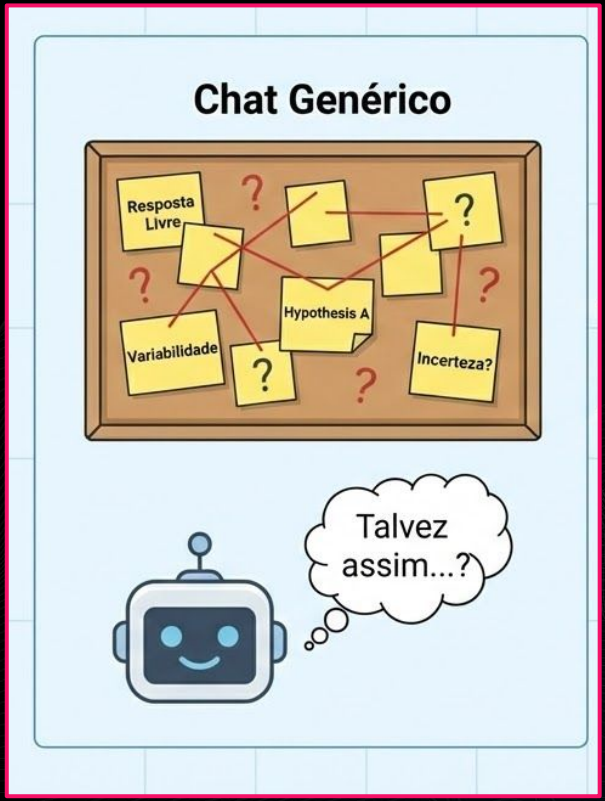

Fonte da imgem: Autor, Nano Banana.

/ RAG
Retrieval-Augmented Generation

R - Retrieve: Encontra informações úteis

A - Augment: Adiciona elas ao conhecimento da IA

G - Generate: Gera uma resposta mais eficiente.

Fonte da imgem: Autor, Nano Banana.

/ RAG
Retrieval-Augmented Generation

RAG é dar ao modelo uma “cola” confiável: antes de gerar a resposta, ele busca informações relevantes em uma base de conhecimento fornecida, e usa isso de contexto

Em extração estruturada, ao invés de uma resposta em texto livre, buscamos que a IA produza dados em um formato padronizado e previsível.

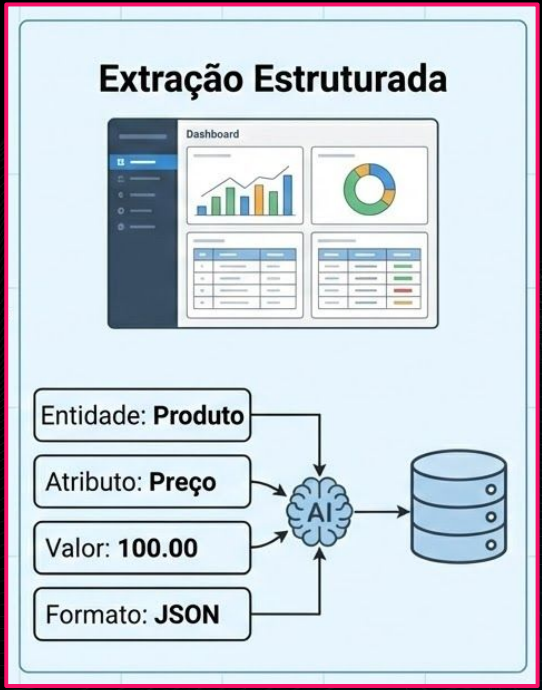

Fonte da imgem: Autor, Nano Banana.

/ RAG

Retrieval-Augmented Generation

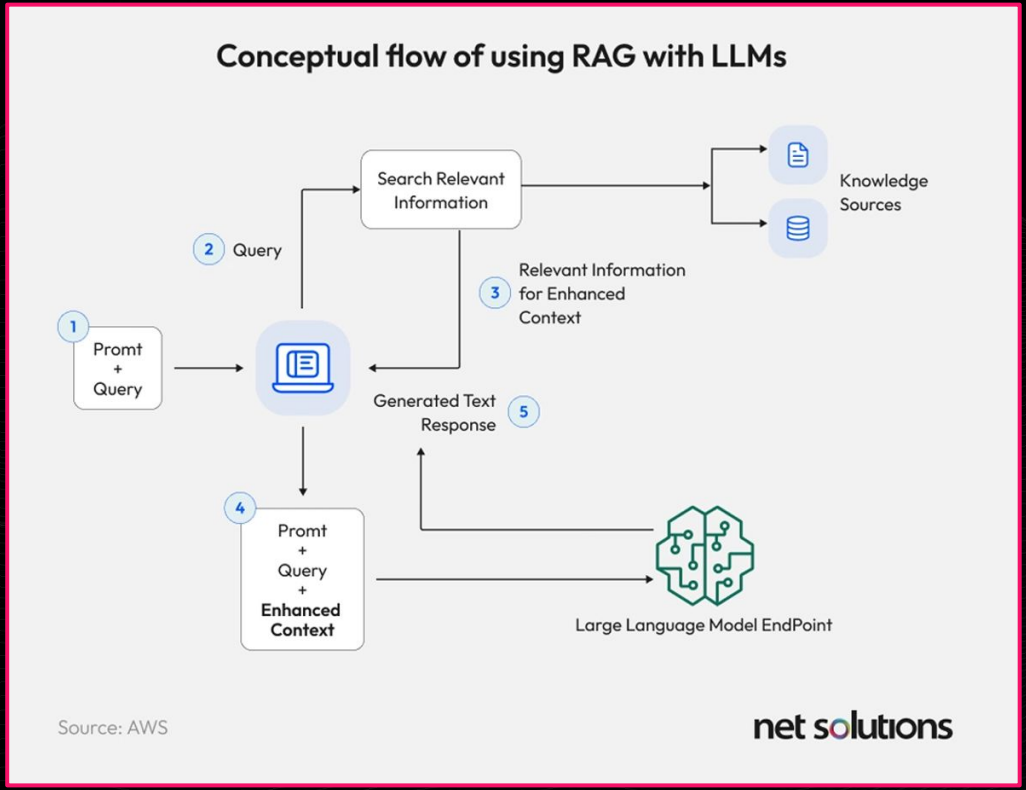

/ E MCP?

/ Para que serve o MCP

Não derrota Boss mas blinda a organização

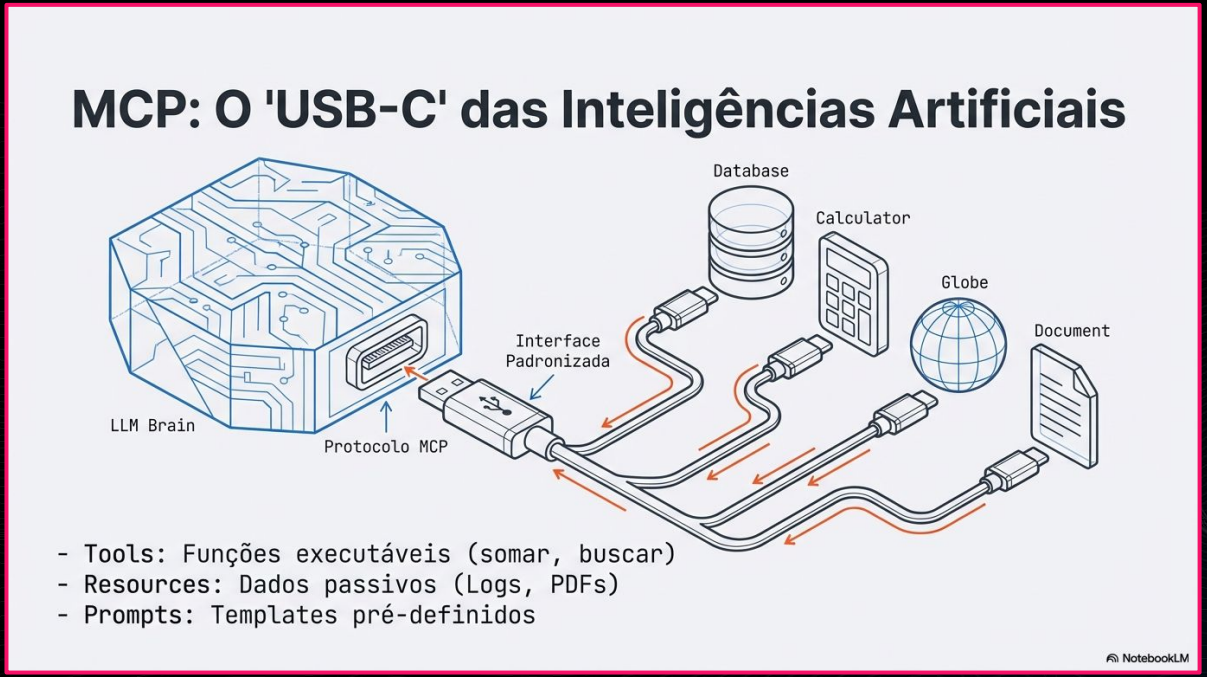

/ Fluxo de Arquitetura

HOST Interface do usuário que decide a experiência e aprovação.

Client Componente que mantém a conexão protocolar dedicada.

Server Servidor que expõe o contexto e as capacidades sistêmicas

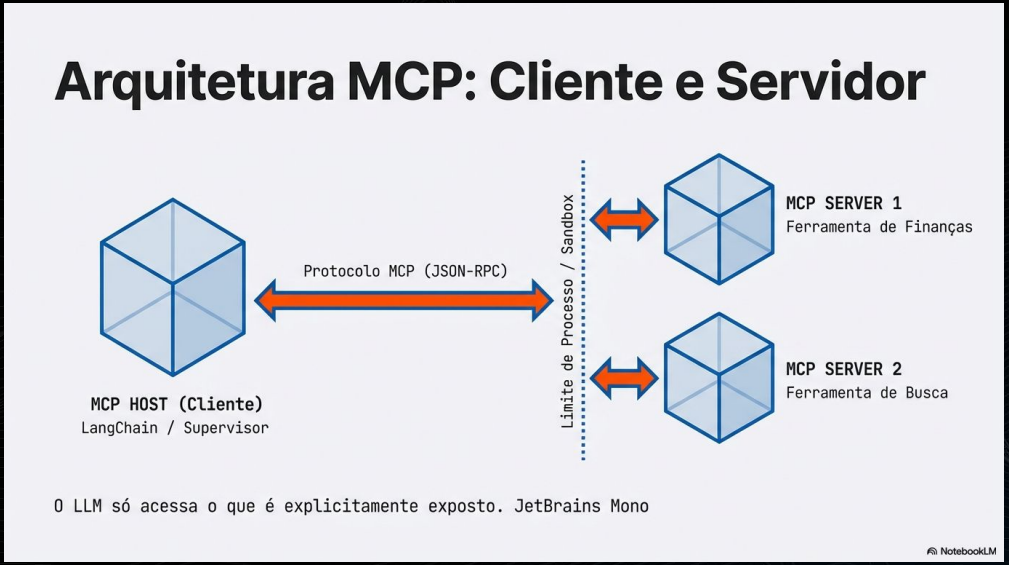

/ Para que serve o MCP

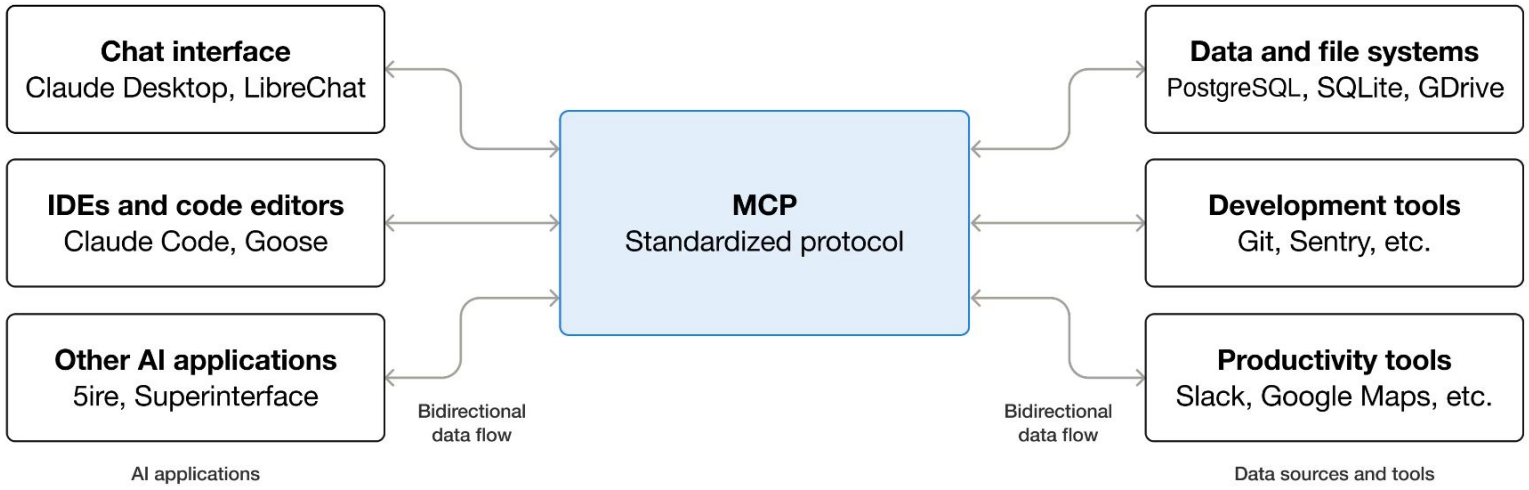

/ As primitivas centrais

Prompt são templates reutilizáveis e parametrizáveis. Eles são pensados para exposição user-controlled, normalmente acionados por slash commands, menus ou UX explícita. “Como eu quero conduzir esta interação?”

Resources são dados contextualizáveis identificados por URI. A especificação os trata como application-driven, o que faz sentido: o cliente decide quando e como anexar contexto ao fluxo da aplicação. “Que contexto devo disponibilizar?”

Tools são capacidades executáveis. Elas são model-controlled no protocolo, embora a especificação recomende fortemente presença humana no loop para operações sensíveis. “Que ação posso executar agora?”

/ As primitivas centrais

O Blueprint do Servidor Python (FastMCP)

```python
from mcp.server.fastmcp import FastMCP
mcp = FastMCP('Policies MCP')

@mcp.resource('policies://catalog')
def policies_catalog() -> str:
    """Catálogo em JSON."""

@mcp.tool()
def search_policies(query: str) -> str:
    """Busca políticas por título."""

if __name__ == '__main__':
    mcp.run(transport='streamable-http')
```

A URI define acesso estável para leitura (Sem side-effects).

Docstrings e Type Hints são automaticamente traduzidos para JSON Schema validado no transporte.

Transporte exposto via rede. O pacote 'mcp[cli]' permite o modo de produção HTTP em vez do frágil stdio.

/ As primitivas centrais

O Osciloscópio do Protocolo: MCP Inspector

MCP Inspector UI

tools/call Request

```
{
  "jsonrpc": "2.0",
  "id": "1",
  "method": "tools/call",
  "params": {
    "name": "search_policies",
    "arguments": {
      "query": "security"
    }
  }
}
```

JSON-RPC Response

```
{
  "jsonrpc": "2.0",
  "id": "1",
  "result": {
    "content": [[
      {"type": "text",
      "text": "Found policy: Security Best
Practices v2.1"}
    ]]
  },
  "isError": false
}
```

REGRA INEGOCIÁVEL: Nunca confie em um servidor não inspecionado.

O Que É:
O Inspector oficial (npx -y @modelcontextprotocol/inspector) é um proxy visual agnóstico de transporte.

Passo 1:
Testar descoberta e isolamento contratual sem o "ruído" do agente LLM.

Passo 2:
Validar se o JSON-RPC de input/output respeita o schema de forma purista.

Passo 3:
Apenas depois de aprovado no Inspector, plugar o servidor no Host (IDE, Chat, Agent).

https://modelcontextprotocol.io/docs/tools/inspector

/ As primitivas centrais

Official MCP Registry

Discover Model Context Protocol servers

GitHub Docs API Reference

Recently Updated

co.heista/api v1.0.0
Decode video ads, load brand intelligence, generate ad scripts.
Updated 11/05/2026

io.github.TopoLift/topolift-mcp v0.2.1
Atom-grounded negotiation reasoning. Typed topology slot, inline citations, public dialect.
Updated 11/05/2026

io.github.safedep/vet-mcp v1.17.0
Protect your AI agents and IDEs from malicious open-source packages.
Updated 11/05/2026

io.github.whw23/searxng-http-mcp v2026.42.0
Self-contained SearXNG metasearch MCP server. One Docker image, 200+ engines, privacy-first.
Updated 11/05/2026

io.github.whw23/searxng-http-mcp v2026.43.0
Self-contained SearXNG metasearch MCP server. One Docker image, 200+ engines, privacy-first.
Updated 11/05/2026

Search servers by name...

☑ Show only latest versions

ac.inference.sh/mcp v1.0.1
Run 150+ AI apps — image, video, audio, LLMs, 3D and more. Browse, execute, stream results.
13/04/2026

Title: inference.sh
Status: Active
View in API
Remotes
`streamable-http` https://sh.inference.ac
`streamable-http` https://api.inference.sh/mcp
▶ View full server.json

ac.tandem/docs-mcp v0.3.2
Remote MCP server for Tandem docs, install guides, SDKs, workflows, and agent setup help.
22/04/2026

agency.lona/trading v2.0.0
AI-powered trading strategy development: backtesting, market data, and portfolio analysis
23/02/2026

ai.aarna/atars-mcp v0.1.0

ai.abmeter/abmeter v0.1.0

ai.adadvisor/mcp-server v1.0.1

https://registry.modelcontextprotocol.io/

/ JSON-RPC e transportes

stdio para integrações locais, em que o cliente dispara o servidor como subprocesso.

Streamable HTTP Componente que mantém a conexão protocolar dedicada.

HTTP+SSE apenas por compatibilidade retroativa, já tratado como legado na documentação.

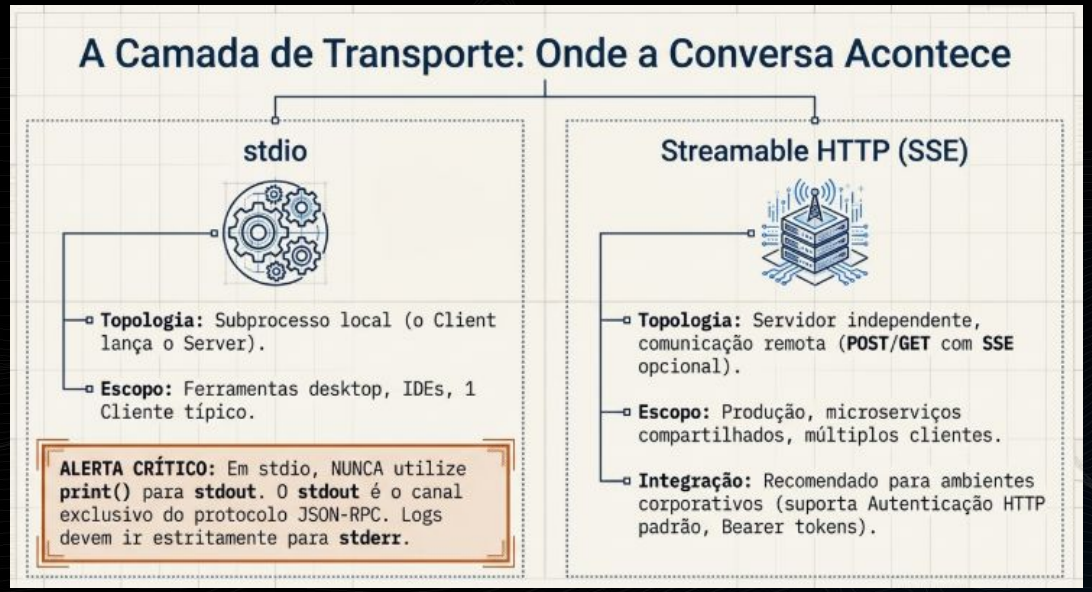

PREPARANDO-SE PARA O AMANHÃ:
UMA JORNADA CONTÍNUA

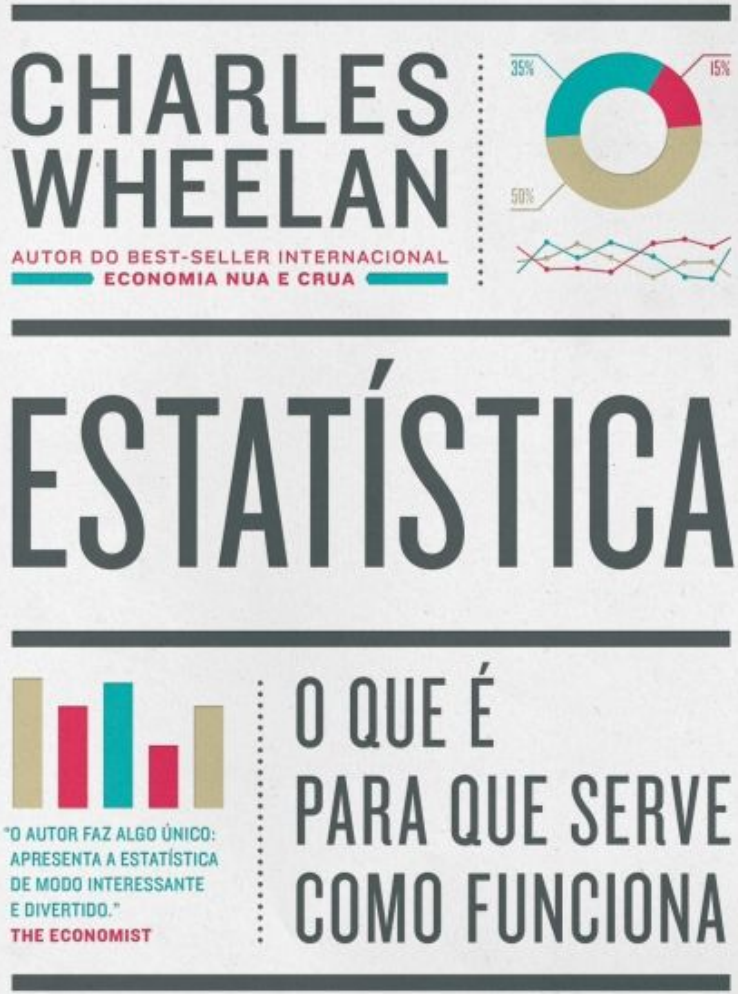

/ Recomendação de leitura

Wheelan, C. (2016). Estatística: o que é, para que serve, como funciona. Editora Zahar.

leitura leve e didática, trazendo as ideias fundamentais da disciplina e mostra por que estatística é uma ferramenta essencial mesmo para aqueles que detestam matemática.

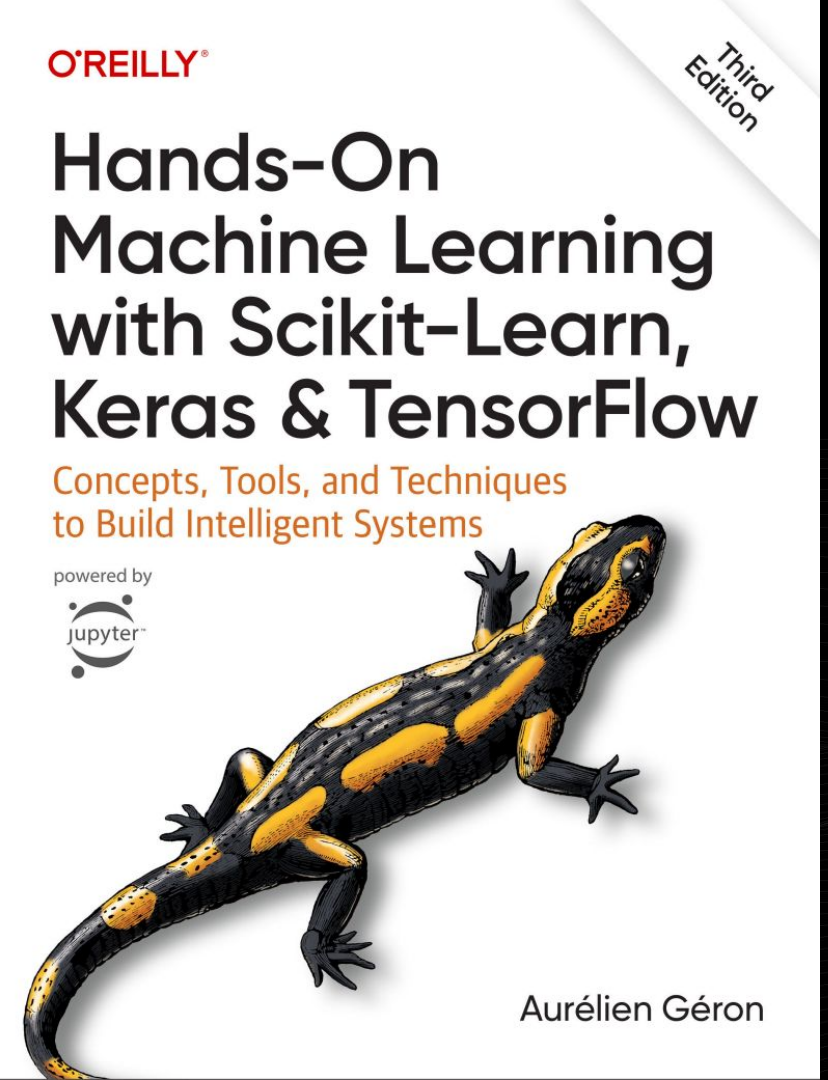

/ Recomendação de leitura

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3ª ed.). O'Reilly Media.

referência didática, com exemplos práticos e explicações profundas sobre algoritmos, pré-processamento e frameworks modernos.

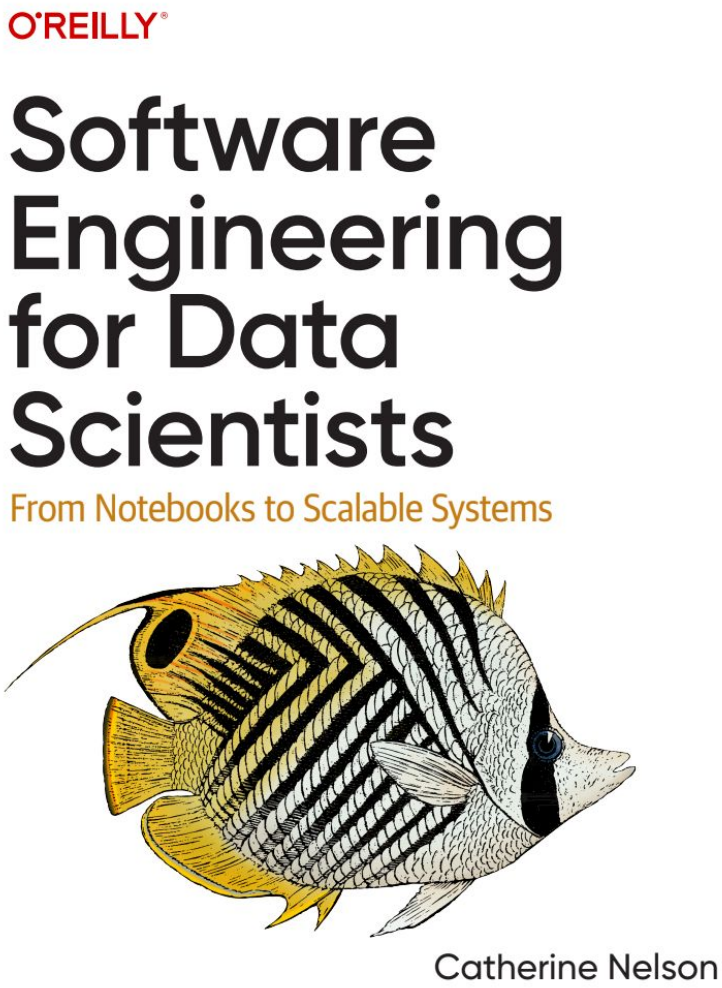

/ Recomendação de leitura

Nelson, C. (2024). Software Engineering for Data Scientists. O'Reilly Media.

Leitura OBRIGATÓRIA para o cientista de dados que quer colocar projetos de data science em produção.

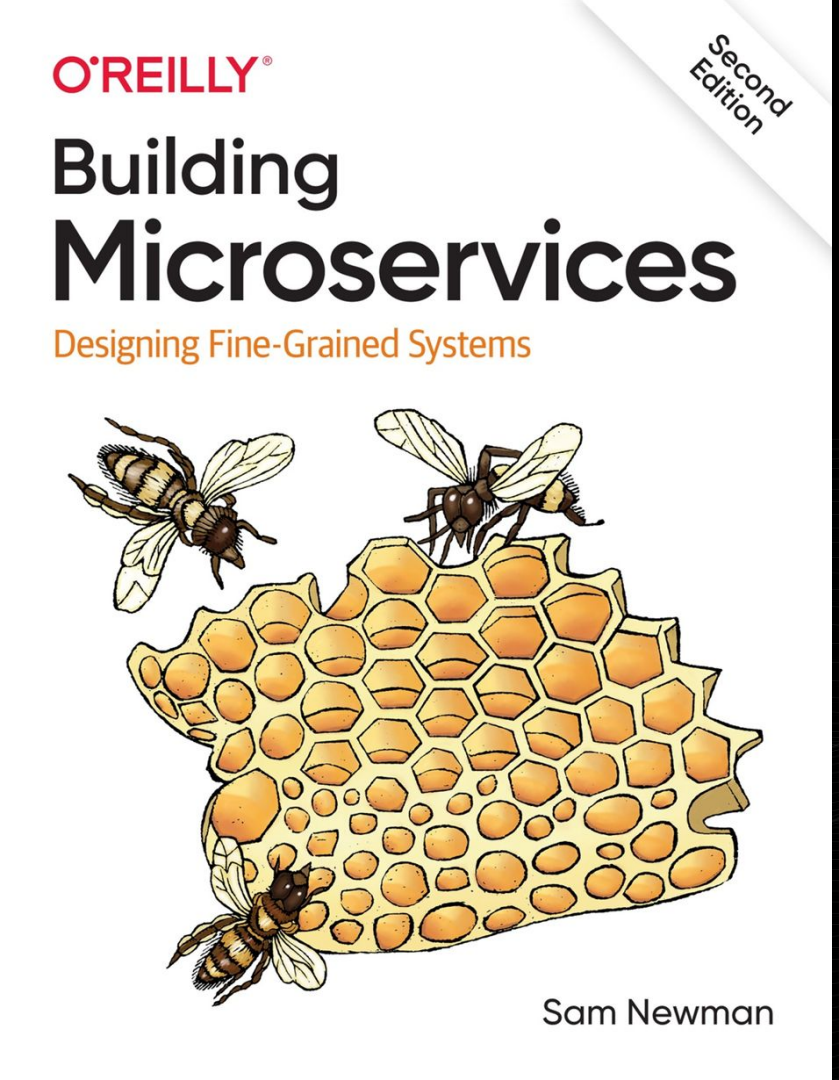

/ Recomendação de leitura

Newman, S. (2021). Building Microservices: Designing Fine-Grained Systems (2ª ed.). O'Reilly Media.

referência técnica, com explicações dos princípios, padrões e trade-offs de arquiteturas de microsserviços.

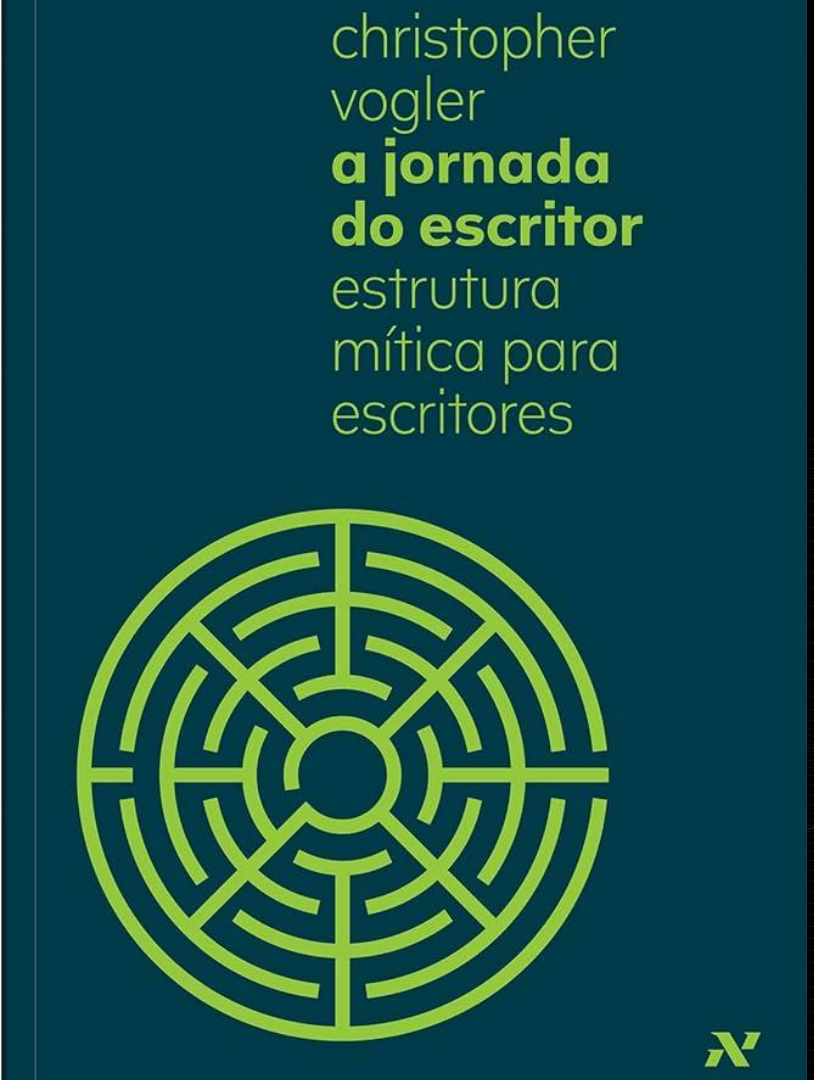

/ Recomendação de leitura

Vogler, C. (2007/ 2007) A jornada do escritor, estrutura mítica para escritores.

Apresenta a “Jornada do Herói” em 12 estágios e 8 arquétipos universais aplicáveis à narrativa.

Ferramenta poderosa para quem conta histórias com dados: transforma números em narrativas com sentido.

Do Androids Dream of Open-Source? O Futuro da IA entre GPT e DeepSeek

A disputa entre modelos de inteligência artificial nunca foi tão intensa, mas essa não é apenas uma batalha técnica, é uma disputa por influência global

Conteúdo por **Prof. Ioannis Pedro Eleftheriou**
25/03/2025 12:45

Deepseek vs GPT - Imagem: Ioannis Eleftheriou | Divulgação

A disputa entre modelos de inteligência artificial nunca foi tão intensa. De um lado, temos o GPT-4o, um modelo fechado, altamente eficiente e operado por uma das maiores empresas de IA do mundo, a OpenAI. Do outro, o DeepSeek, um modelo open-source que aposta na transparência e no acesso democrático à IA. Mas essa não é apenas uma batalha técnica, trata-se de uma disputa por influência global e pelo domínio sobre a infraestrutura da inteligência artificial e do conhecimento.

A ascensão desses modelos redefine o que entendemos como inteligência artificial e quem terá acesso a seus benefícios, intensificando a tensão entre centralização e descentralização do conhecimento. Para entender as implicações disso, é essencial olhar além da capacidade bruta dos modelos e analisar como eles moldam nossa relação com a tecnologia e o futuro da inovação.

O que é Real e o que é Máquina?

/ Recomendação de leitura

Autor: Prof. Ioannis Pedro Eleftheriou — Do Androids Dream of Open-Source? O Futuro da IA entre GPT e DeepSeek.

Disputa entre modelos de IA fechados (ex: GPT-4o) e open-source (ex: DeepSeek) é mais que tecnologia, é uma batalha por poder e acesso.

Devemos nos perguntar: O que queremos que a IA seja para a sociedade?

Link:
https://catracalivre.com.br/jogos/do-androids-dream-of-open-source-o-futuro-da-ia-entre-gpt-e-deepseek/

AVALIAÇÃO DE REAÇÃO

bitly